

ÁLGEBRA LINEAR II

RODRIGO MATOS

1. AUTOVALORES E AUTOVETORES

Definição 1. *Seja $A_{n \times n}$ uma matriz dada. Dizemos que $\lambda \in \mathbb{C}$ é um autovalor de A quando $Ax = \lambda x$ para algum vetor não nulo $x \in \mathbb{R}^n$. Nesse caso, x é dito um autovetor de $A_{n \times n}$.*

Em geral encontrar autovalores parece difícil pois aparenta envolver a busca por autovetores. Porém...

Proposição 1. $\lambda \in \mathbb{C}$ é um autovalor de A se e somente se

$$(1) \quad \det(A - \lambda I) = 0$$

onde I denota a matriz identidade $n \times n$.

Demonstração.

$$Ax = \lambda x \iff (A - \lambda I)x = 0 \text{ para algum } x \neq \vec{0}.$$

Porém $(A - \lambda I)x = 0$ admite solução não nula x se e somente se $(A - \lambda I)$ é uma matriz singular, ou seja quando $\det(A - \lambda I) = 0$.

□

Definição 2.

$$p_A(\lambda) := \det(A - \lambda I) = 0$$

é dito o polinômio característico de A .

Quando a matriz estiver subentendida, escreveremos por simplicidade $p(\lambda)$ ao invés de $p_A(\lambda)$.

Exemplo 1. *Encontre os autovalores e autovetores da matriz $A = \begin{pmatrix} 4 & -5 \\ 2 & -3 \end{pmatrix}$.*

Solução. Nesse caso, temos

$$\det(A - \lambda I) = \det \begin{pmatrix} 4 - \lambda & -5 \\ 2 & -3 - \lambda \end{pmatrix} = \lambda^2 - \lambda - 2.$$

Logo, $p_A(\lambda) = 0$ equivale a $\lambda^2 - \lambda - 2 = 0$, ou seja, $\lambda = -1$ ou $\lambda = 2$. Então a matriz possui dois autovalores, digamos $\lambda_1 = -1$ e $\lambda_2 = 2$. Vamos agora encontrar os autovetores:

- Autovetores para $\lambda_1 = -1$:

De acordo com a definição $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ é autovetor associado a λ_1 quando vale o seguinte

$$\begin{aligned} (A - \lambda_1 I) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \iff \begin{pmatrix} 5 & -5 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \iff \begin{cases} 5x_1 - 5x_2 = 0 \\ 2x_1 - 2x_2 = 0. \end{cases} \end{aligned}$$

O sistema linear acima possui infinitas soluções da forma $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} t \\ t \end{pmatrix}$ de onde concluímos que os autovetores para $\lambda_1 = -1$ tomam a forma $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} t \\ t \end{pmatrix}$ para algum $t \neq 0$.

- Autovetores para $\lambda_2 = 2$:

Similarmente $\begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ é autovetor associado a λ_2 quando

$$\begin{aligned} (A - \lambda_2 I) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \iff \begin{pmatrix} 2 & -5 \\ 2 & -5 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \iff \begin{cases} 2y_1 - 5y_2 = 0 \\ 2y_1 - 5y_2 = 0. \end{cases} \end{aligned}$$

Em particular os autovetores para $\lambda_2 = 2$ tomam a forma $\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} s \\ \frac{2s}{5} \end{pmatrix}$ para algum $s \neq 0$.

□

No exemplo acima, os autovetores associados a $\lambda_1 = -1$ e $\lambda_2 = 2$ praticamente coincidem com as retas $\ell_1 = \left\{ \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2 : x_1 = x_2 \right\}$ e $\ell_2 = \left\{ \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2 : x_2 = \frac{2x_1}{5} \right\}$ exceto pelo fato de que estas retas contém o vetor nulo $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$. Isto motiva a seguinte definição.

Definição 3. Seja $A_{n \times n}$ uma matriz quadrada com autovalor $\lambda \in \mathbb{C}$. O autoespaço associado a λ , denotado aqui por E_λ é o conjunto solução do sistema linear $Ax = \lambda x$.

Observação 1. Por definição, segue que

$$E_\lambda = \{\text{autovetores de } A \text{ associados a } \lambda\} \cup \{\vec{0}\}.$$

Definição 4. Um subconjunto $S \subset V$ de um espaço vetorial é dito um subespaço de V quando as seguintes condições são satisfeitas:

- (a) $\vec{0}$ pertence a S .
- (b) Se $u \in S$ e $v \in S$ então $u + v \in S$.
- (c) Se $u \in S$ e $\alpha \in \mathbb{R}$ então $\alpha u \in S$.

Proposição 2. Seja $A_{n \times n}$ uma matriz quadrada com autovalor $\lambda \in \mathbb{R}$. Então o autoespaço E_λ é um subespaço vetorial de $\mathbb{R}^n$.

Demonstração. Vamos checar as condições acima da definição de subespaço trocando S por E_λ .

- (a) Se $u \in E_\lambda$ e $v \in E_\lambda$ isto significa que $Au = \lambda u$ e $Av = \lambda v$. Logo

$$\begin{aligned} A(u + v) &= Au + Av \\ &= \lambda u + \lambda v \\ &= \lambda(u + v) \end{aligned}$$

da onde vemos que $u + v$ também pertence a E_λ como queríamos.

- (b) Se $u \in E_\lambda$ e $\alpha \in \mathbb{R}$ então

$$\begin{aligned} A(\alpha u) &= \alpha(Au) \\ &= \alpha(\lambda u) \\ &= \lambda(\alpha u) \end{aligned}$$

portanto αu pertence a E_λ .

□

Observação 2. Mais adiante, veremos que a noção de autoespaço está intimamente conectada com a noção de espaço nulo de uma matriz. De fato, $E_\lambda = N(A - \lambda I)$, onde $N(\cdot)$ denota o espaço nulo.

Exemplo 2. Seja $A = \begin{pmatrix} 4 & -5 \\ 2 & -3 \end{pmatrix}$ a matriz do exemplo 1. Calcule

- (a) $A^{2025} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$
- (b) $A^{2026} \begin{pmatrix} -7 \\ -7 \end{pmatrix}$.
- (c) $A^{2025} \begin{pmatrix} 5 \\ 2 \end{pmatrix}$.
- (d) $A^{2025} \begin{pmatrix} 6 \\ 3 \end{pmatrix}$.

Solução. (a) Sabemos do exemplo 1 que $A \begin{pmatrix} 1 \\ 1 \end{pmatrix} = (-1) \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. Logo,

$$\begin{aligned} A^2 \begin{pmatrix} 1 \\ 1 \end{pmatrix} &= A[A \begin{pmatrix} 1 \\ 1 \end{pmatrix}] \\ &= A[(-1) \begin{pmatrix} 1 \\ 1 \end{pmatrix}] \\ &= (-1)A \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= (-1)^2 \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= \begin{pmatrix} 1 \\ 1 \end{pmatrix}. \end{aligned}$$

Procedendo desta forma, vemos que $A^{2025} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = (-1)^{2025} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ -1 \end{pmatrix}$

(b) Também do exemplo 1 sabemos que $\begin{pmatrix} -7 \\ -7 \end{pmatrix}$ é um autovetor associado ao autovalor $\lambda_1 = -1$. Desta forma, procedendo como no item anterior encontramos $A^{2026} \begin{pmatrix} -7 \\ -7 \end{pmatrix} = (-1)^{2026} \begin{pmatrix} -7 \\ -7 \end{pmatrix} = \begin{pmatrix} -7 \\ -7 \end{pmatrix}$.

(c) Tomando $s = 5$ no exemplo 1, temos que $\begin{pmatrix} 5 \\ 2 \end{pmatrix}$ é um autovetor associado ao autovalor $\lambda_2 = 2$. Portanto $A^{2025} \begin{pmatrix} 5 \\ 2 \end{pmatrix} = 2^{2025} \begin{pmatrix} 5 \\ 2 \end{pmatrix}$.

(d) Aqui, $\begin{pmatrix} 6 \\ 3 \end{pmatrix}$ não é um autovetor então não podemos seguir imediatamente como nos itens anteriores. Porém, podemos notar que $\begin{pmatrix} 6 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} 5 \\ 2 \end{pmatrix}$ e assim calcular

$$\begin{aligned} A^{2025} \begin{pmatrix} 6 \\ 3 \end{pmatrix} &= A^{2025} \left[\begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} 5 \\ 2 \end{pmatrix} \right] \\ &= A^{2025} \begin{pmatrix} 1 \\ 1 \end{pmatrix} + A^{2025} \begin{pmatrix} 5 \\ 2 \end{pmatrix} \\ &= \begin{pmatrix} -1 \\ -1 \end{pmatrix} + 2^{2025} \begin{pmatrix} 5 \\ 2 \end{pmatrix} \\ &= \begin{pmatrix} 5 \cdot 2^{2025} - 1 \\ 2^{2026} - 1 \end{pmatrix} \end{aligned}$$

onde na penúltima igualdade utilizamos os itens acima.

□

Observação 3. Na solução do último item do exemplo acima, surge uma pergunta natural: a decomposição $\begin{pmatrix} 6 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} 5 \\ 2 \end{pmatrix}$ foi apenas um golpe de sorte? E quanto a outros vetores diferentes de $\begin{pmatrix} 6 \\ 3 \end{pmatrix}$? De fato, os autovetores $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ e $\begin{pmatrix} 5 \\ 2 \end{pmatrix}$ formam uma base para $\mathbb{R}^2$ logo qualquer vetor em $\mathbb{R}^2$ pode ser escrito como uma combinação linear deles. Por exemplo, $\begin{pmatrix} 47 \\ 17 \end{pmatrix} = (-3) \begin{pmatrix} 1 \\ 1 \end{pmatrix} + (10) \begin{pmatrix} 5 \\ 2 \end{pmatrix}$. Voltaremos a este tópico um pouco mais adiante.

Exemplo 3. (a) Encontre os autovalores e autovetores da matriz $B = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$.

(b) Existe uma base de $\mathbb{R}^2$ formada por autovetores de A ?

Solução. (a) $p_B(\lambda) = \det(B - \lambda I) = \det \begin{pmatrix} -\lambda & 1 \\ 0 & -\lambda \end{pmatrix} = \lambda^2$ e, portanto, $p_B(\lambda) = 0$ somente quando $\lambda = 0$. Daí, B possui somente um autovalor $\lambda_1 = 0$. Nesse caso um autovetor associado $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ resolve $\begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ ou seja $x = \begin{pmatrix} t \\ 0 \end{pmatrix}$ para algum $t \neq 0$.

(b) Pelo item anterior, existe somente um autoespaço associado a B , a saber o autoespaço

$$E_0 = \left\{ \begin{pmatrix} t \\ 0 \end{pmatrix}, t \in \mathbb{R} \right\}.$$

Porém, E_0 é uma reta e, portanto, não pode conter o plano $\mathbb{R}^2$.

□

2. SUBESPAÇOS FUNDAMENTAIS

Alguns subespaços de $\mathbb{R}^n$ são ditos fundamentais pela sua relevância para o estudo de sistemas lineares.

Definição 5. Seja $A_{m \times n}$ uma matriz $m \times n$. O espaço nulo de A é o conjunto

$$(2) \quad N(A) = \{v \in \mathbb{R}^n : Av = 0\}$$

Observação 4. Em particular, se λ é um autovalor de A , temos a seguinte relação entre o espaço nulo de $A - \lambda I$ e o autoespaço associado a λ : $N(A - \lambda I) = E_\lambda$.

Exemplo 4. Seja $A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$. Então $v = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} \in \mathbb{R}^3$ pertence ao espaço nulo de A quando

$$\begin{aligned} Av &= \vec{0} \\ \iff \begin{pmatrix} v_1 \\ 0 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \iff v_1 &= 0. \end{aligned}$$

Portanto

$$(3) \quad N(A) = \left\{ \begin{pmatrix} 0 \\ t \\ s \end{pmatrix} : s, t \in \mathbb{R} \right\}.$$

Exemplo 5. Seja $I = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$. Então $v \in N(I) \iff Iv = \vec{0}$ ou seja, quando $v = \vec{0}$ portanto $N(I) = \{\vec{0}\}$.

Exemplo 6. Seja $B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$. Então

$$v = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} \in \mathbb{R}^3 \iff \begin{pmatrix} v_1 \\ v_2 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}.$$

ou seja, quando $v_1 = v_2 = 0$. Assim

$$(4) \quad N(B) = \left\{ \begin{pmatrix} 0 \\ 0 \\ t \end{pmatrix} : t \in \mathbb{R} \right\}.$$

Proposição 3. Seja $A_{m \times n}$ uma matriz $m \times n$. Então $N(A)$ é um subespaço de $\mathbb{R}^n$.

Demonstração. Vamos checar os requerimentos da definição de subespaço.

- (a) $A\vec{0} = \vec{0}$ e assim $\vec{0} \in N(A)$.
- (b) Se $u, v \in N(A)$ então $A(u + v) = Au + Av = \vec{0} + \vec{0} = \vec{0}$ portanto $u + v \in N(A)$.
- (c) Se $v \in N(A)$ e $\alpha \in \mathbb{R}$ então $A(\alpha v) = \alpha(Av) = \alpha\vec{0} = \vec{0}$ portanto $\alpha v \in N(A)$.

□

Observação 5. Operações elementares sobre a matriz de um sistema linear não alteram o seu conjunto solução. Em particular, se U é uma forma escalonada de A então $N(A) = N(U)$

Exemplo 7. Seja $C = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & 2 & 0 \end{pmatrix}$. Encontre o espaço nulo de C .

Solução. As operações elementares $\ell_3 \rightarrow \ell_3 - 2\ell_2$ e $\ell_2 \rightarrow \ell_2 - \ell_1$ (realizadas nessa ordem) transformam C na matriz $B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$ do exemplo 6. Daí, podemos concluir que

$$N(C) = N(B) = \left\{ \begin{pmatrix} 0 \\ 0 \\ t \end{pmatrix} : t \in \mathbb{R} \right\}.$$

□

Definição 6. (a) Dada $A_{m \times n}$, o espaço-coluna de A , denotado por $C(A)$, é o subespaço de $\mathbb{R}^m$ gerado pelos vetores coluna de A .

(b) O espaço-linha de A é, por definição, o espaço coluna de sua transposta, $C(A^T)$.

Exemplo 8. Se $B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$ então

$$C(B) = \text{Ger}\left\{\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}\right\} = \left\{\begin{pmatrix} t \\ s \\ 0 \end{pmatrix} : s, t \in \mathbb{R}\right\}.$$

Aqui, denotamos por $\text{Ger}\{v_1, \dots, v_n\}$ o subespaço gerado pelos vetores $v_1, \dots, v_n$, ou seja, o conjunto de todas as combinações lineares $\alpha_1 v_1 + \dots + \alpha_n v_n$ possíveis a partir deste vetores.

Exemplo 9. Se $A = \begin{pmatrix} 1 & 2 & 0 \\ 3 & 6 & 0 \end{pmatrix}$ então o espaço coluna de A é dado por

$$C(A) = \text{Ger}\left\{\begin{pmatrix} 1 \\ 3 \end{pmatrix}, \begin{pmatrix} 2 \\ 6 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix}\right\} = \left\{\begin{pmatrix} t \\ 3t \end{pmatrix} : t \in \mathbb{R}\right\}.$$

Por outro lado, seu espaço-linha é

$$C(A^T) = \text{Ger}\left\{\begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}, \begin{pmatrix} 3 \\ 6 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}\right\} = \left\{\begin{pmatrix} t \\ 2t \\ 0 \end{pmatrix} : t \in \mathbb{R}\right\}.$$

2.1. Operações e matrizes elementares. Este é um momento oportuno para revisarmos as operações elementares utilizadas para resolver um sistema linear e as matrizes associadas a elas.

Definição 7. As seguintes operações em uma matriz são ditas elementares.

- (a) Trocar a posição de duas linhas.
- (b) Multiplicar uma linha por um número diferente de zero.
- (c) Trocar uma linha por sua soma com um múltiplo de outra linha.

Definição 8. Seja n um inteiro positivo dado. Uma matriz elementar de ordem n é uma matriz $n \times n$ obtida a partir da matriz identidade $n \times n$ através de **exatamente uma** operação elementar.

Exemplo 10. Se $I = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ então aplicando a operação elementar $\ell_3 \longleftrightarrow \ell_2$ a I obtemos a matriz elementar $E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$. Similarmente, as operações $\ell_2 \rightarrow \ell_2 - \ell_1$

e $\ell_3 \rightarrow 5\ell_3$ (aplicadas a I separadamente) produzem, respectivamente, as matrizes elementares $F = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ e $G = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 5 \end{pmatrix}$.

O papel das matrizes elementares pode ser observado a partir dos seguintes cálculos. Se E, F, G são como no exemplo 10 e $A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$ então $EA = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{31} & a_{32} & a_{33} \\ a_{21} & a_{22} & a_{23} \end{pmatrix}$,
 $FA = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} - a_{11} & a_{22} - a_{12} & a_{23} - a_{13} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$ e $GA = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ 5a_{31} & 5a_{32} & 5a_{33} \end{pmatrix}$.

Observação 6. Em geral, multiplicar à esquerda uma matriz $A_{n \times l}$ por uma matriz elementar $E_{n \times n}$ obtida de $I_{n \times n}$ através da operação elementar $\mathcal{L}$ equivale a realizar esta mesma operação elementar $\mathcal{L}$ na matriz A .

Exemplo 11. Vamos escalonar a matriz $A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1/5 \\ 1 & 1 & 0 \end{pmatrix}$ utilizando matrizes elementares.

Aplicando $\ell_3 \longleftrightarrow \ell_2$ através da multiplicação por $E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$ obtemos

$EA = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1/5 \end{pmatrix}$. Depois, aplicamos $\ell_2 \rightarrow \ell_2 - \ell_1$ através de $F = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ para

obter $FEA = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1/5 \end{pmatrix}$. Finalmente, fazendo $\ell_3 \rightarrow 5\ell_3$ através da multiplicação por

$G = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 5 \end{pmatrix}$ concluímos que $GFEA = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$.

2.2. Fatorações $A = LU$ e $PA = LU$. Para motivar as fatorações $A = LU$ e $PA = LU$

vamos escalonar a matriz $A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix}$. Isto se dá em três passos, a saber

- $\ell_2 \rightarrow \ell_2 - 2\ell_1$ através da multiplicação por $E = \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ obtemos

$$EA = \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ -2 & 7 & 2 \end{pmatrix}.$$

- Depois, $\ell_3 \rightarrow \ell_3 + \ell_1$ através de $F = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$ nos dá $FEA = \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 8 & 3 \end{pmatrix}$.
- Por último, com $\ell_3 \rightarrow \ell_3 + \ell_2$ através de $G = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}$ concluimos que $GFEA = \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix}$.

Vemos assim que se $U = \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix}$ então $GFEA = U$. Uma vez verificado que as matrizes E, F, G são invertíveis, poderemos escrever

$$(5) \quad A = (GFE)^{-1}U = E^{-1}F^{-1}G^{-1}U$$

Explicitamente,

- $E^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$
- $F^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$
- $G^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix}$

Exercício 1. Verificar as fórmulas acima e observar o padrão para a inversa de uma matriz elementar qualquer.

Segue então de (5) que $A = LU$ onde

$$\begin{aligned} L &= E^{-1}F^{-1}G^{-1} \\ &= \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix}. \end{aligned}$$

Finalmente, note a estrutura da equação $A = LU$:

$$(6) \quad \begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix}.$$

Ou seja, fatoramos A como o produto de duas matrizes sendo uma delas, L , triangular inferior (*Lower triangular*, em inglês) e a outra, U , triangular superior (*Upper triangular*, em inglês).

Exercício 2. Encontre a fatoração $A = LU$ para $A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$.

Surge então a pergunta natural: toda matriz pode ser fatorada como produto de uma matriz triangular inferior por uma matriz triangular superior?

Exemplo 12. Verifique que $A = \begin{pmatrix} 0 & 2 \\ 3 & 4 \end{pmatrix}$ não admite uma fatoração $A = LU$.

Solução. Se $L = \begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix}$ e $U = \begin{pmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{pmatrix}$ então $LU = \begin{pmatrix} l_{11}u_{11} & l_{11}u_{12} \\ l_{21}u_{11} & l_{21}u_{12} + l_{22}u_{22} \end{pmatrix}$. Portanto, se $A = LU$ devemos ter $l_{11}u_{11} = 0$. Esta equação leva a duas possibilidades.

- (i) $l_{11} = 0$. Nesse caso, se $A = LU$, devemos ter $l_{11}u_{12} = a_{12}$, ou seja $0 = 2$, o que não é possível.
- (ii) $u_{11} = 0$: Analogamente, aqui seguiria $a_{21} = l_{21}u_{11}$ implica $3 = 0$ o que também leva a uma contradição.

Deste modo, a matriz $A = \begin{pmatrix} 0 & 2 \\ 3 & 4 \end{pmatrix}$ não possui uma fatoração $A = LU$.

□

O exemplo acima motiva a fatoração $PA = LU$. Note que se $P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ e $A = \begin{pmatrix} 0 & 2 \\ 3 & 4 \end{pmatrix}$ então a matriz $PA = \begin{pmatrix} 3 & 4 \\ 0 & 2 \end{pmatrix}$ admite uma fatoração trivial $PA = LU = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 3 & 4 \\ 0 & 2 \end{pmatrix}$.

Apresentamos abaixo dois resultados sobre as fatorações $A = LU$ e $PA = LU$ cujas demonstrações seguem o raciocínio dos exemplos acima sendo aqui omitidas.

Definição 9. Dizemos que uma matriz A pode ser reduzida por baixo quando A pode ser posta na forma escalonada sem necessidade de trocar suas linhas.

Teorema 1. Se A pode ser reduzida por baixo então existe uma fatoração $A = LU$, com L triangular inferior e invertível e U triangular superior.

Definição 10. Uma matriz de permutação de ordem n é uma matriz elementar obtida da identidade por uma troca de linhas.

Teorema 2. *Sejam $P_1 \dots P_r$ as matrizes de permutação utilizadas (nesta ordem) no processo de escalonamento da matriz A . Então, se $P = P_r \dots P_1$ a matriz PA admite uma fatoração $PA = LU$, com L triangular inferior e U triangular superior.*

Exemplo 13. Para escalonar $A = \begin{pmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 1 & 1 \end{pmatrix}$ utilizamos duas trocas de linhas em sequência, por exemplo, as trocas $\ell_1 \longleftrightarrow \ell_3$ e depois $\ell_2 \longleftrightarrow \ell_3$ correspondentes às matrizes de permutação $P_1 = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$ e $P_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$. Então, se $U = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$ e $P = P_2 P_1 = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$ temos $PA = LU$ para $L = I_{3 \times 3}$.

Observação 7. *Suponha que $A = LU$, com L invertível. Então um sistema linear da forma $Ax = b$ pode ser resolvido do seguinte modo: definimos $c = L^{-1}b$ e resolvemos $Ux = c$. Assim, $Ux = L^{-1}b \iff Ax = LUx = b$.*

Exemplo 14. Se $A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$ é como no exercício 2 temos então $A = LU$ com $L = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}$ e $U = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$. Nesse caso, se $x = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ estudamos o sistema $Ax = b$ usando $L^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix}$, $c = L^{-1}b = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$ e resolvendo $Ux = c$ que é simplesmente

$$\begin{cases} x_1 + x_2 + x_3 = 1 \\ x_2 + x_3 = 0 \\ x_3 = 0 \end{cases}$$

3. ORTOGONALIDADE

Definição 11. *Sejam $u = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$ e $v = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$ vetores em $\mathbb{R}^n$. Definimos o produto interno de u por v como*

$$(7) \quad \langle u, v \rangle = u_1 v_1 + \dots + u_n v_n.$$

Proposição 4 (Propriedades do produto interno). (a) $\langle u, v \rangle = \langle v, u \rangle$ (Comutatividade)
 (b) $\langle u + \alpha v, w \rangle = \langle u, w \rangle + \alpha \langle v, w \rangle$ (distributividade à esquerda)
 (c) $\langle w, u + \alpha v \rangle = \langle w, u \rangle + \alpha \langle w, v \rangle$ (distributividade à direita)
 (d) $\langle u, u \rangle \geq 0$ com igualdade se, e somente se, $u = \vec{0}$ (positividade)

Demonstração. (a) Segue imediatamente da definição.

(b) Vamos definir $u = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$, $v = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$ e $w = \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix}$. Então, $u + \alpha w = \begin{pmatrix} u_1 + \alpha w_1 \\ \vdots \\ u_n + \alpha w_n \end{pmatrix}$.

Portanto,

$$\begin{aligned} \langle u + \alpha v, w \rangle &= (u_1 + \alpha v_1)w_1 + \dots + (u_n + \alpha v_n)w_n \\ &= (u_1w_1 + \alpha v_1w_1) + \dots + (u_nw_n + \alpha v_nw_n) \\ &= (u_1w_1 + \dots + u_nw_n) + (\alpha v_1w_1 + \dots + \alpha v_nw_n) \\ &= (u_1w_1 + \dots + u_nw_n) + \alpha(v_1w_1 + \dots + v_nw_n) \\ &= \langle u, w \rangle + \alpha \langle v, w \rangle \end{aligned}$$

(c) Segue das duas propriedades anteriores.

(d) Basta notar que $\langle u, u \rangle = u_1^2 + \dots + u_n^2$ e que esta expressão se anula em um único caso. A saber, quando $u_1 = \dots = u_n = 0$.

□

Definição 12. Definimos o comprimento de $u = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$ como

$$|u| = \sqrt{u_1^2 + \dots + u_n^2}.$$

Observação 8. É imediato checar que $|u|^2 = \langle u, u \rangle$.

Exemplo 15. Se $u = \begin{pmatrix} 3 \\ 4 \\ 0 \end{pmatrix}$ e $u_\alpha = \begin{pmatrix} 3\alpha \\ 4\alpha \\ 0 \end{pmatrix}$ com $\alpha \in \mathbb{R}$ então $|u| = 5$ e $|u_\alpha| = 5|\alpha|$.

Exemplo 16. Se $u = \begin{pmatrix} 3 \\ 4 \\ 0 \end{pmatrix}$ e $v = \begin{pmatrix} -4 \\ 3 \\ 0 \end{pmatrix}$ então $\langle u, v \rangle = 0$.

Definição 13. Dizemos que dois vetores em $\mathbb{R}^n$ são ortogonais, e escrevemos $u \perp v$, quando $\langle u, v \rangle = 0$.

Teorema 3 (Pitágoras). Se $u \perp v$ então

$$|u + v|^2 = |u|^2 + |v|^2.$$

Demonstração.

$$\begin{aligned} |u + v|^2 &= \langle u + v, u + v \rangle \\ &= \langle u, u + v \rangle + \langle v, u + v \rangle \\ &= \langle u, u \rangle + \langle u, v \rangle + \langle v, u \rangle + \langle v, v \rangle \\ &= |u|^2 + |v|^2. \end{aligned}$$

□

Observação 9. Trocando v por $-v$ no Teorema 3 concluímos que $|u - v|^2 = |u|^2 + |v|^2$.

Definição 14. Sejam $S_1 \subset \mathbb{R}^n$ e $S_2 \subset \mathbb{R}^n$ subespaços de $\mathbb{R}^n$. Dizemos que S_1 e S_2 são ortogonais, e escrevemos $S_1 \perp S_2$, quando $x \perp v$ para cada x em S_1 e v em S_2 .

Definição 15. Seja $S \subset \mathbb{R}^n$ um subespaço. O complemento ortogonal de S é

$$S^\perp = \{x \in \mathbb{R}^n : \langle x, v \rangle = 0 \text{ para todo } v \text{ em } S\}.$$

Observação 10. Por definição, $S^\perp$ é “o maior” subespaço de $\mathbb{R}^n$ ortogonal a S .

Exemplo 17. Sejam S_1 , S_2 e S_3 os eixos x, y e z de $\mathbb{R}^3$, respectivamente.

$$S_1 = \{(x_1, 0, 0) : x_1 \in \mathbb{R}\},$$

$$S_2 = \{(0, x_2, 0) : x_2 \in \mathbb{R}\},$$

$$S_3 = \{(0, 0, x_3) : x_3 \in \mathbb{R}\}.$$

Então podemos verificar o seguinte:

- $S_1 \perp S_2$, $S_1 \perp S_3$ e $S_2 \perp S_3$. Por exemplo, $S_1 \perp S_2$ segue de que $(x_1, 0, 0) \perp (0, x_2, 0)$ para quaisquer valores de x_1 e x_2 .
- $S_1^\perp = \{(0, x_2, x_3) : x_2 \in \mathbb{R}, x_3 \in \mathbb{R}\}$. Ou seja, o complemento ortogonal do eixo x em $\mathbb{R}^3$ é o plano yz .

Para verificar esta afirmação devemos checar duas coisas:

- (1) Todo vetor no plano yz está em $S_1^\perp$.
- (2) Todo vetor em $S_1^\perp$ está no plano yz .

De fato, denotando por $\Sigma_{yz} = \{(0, x_2, x_3) : x_2 \in \mathbb{R}, x_3 \in \mathbb{R}\}$ o plano yz , vale o seguinte:

- (1) Se $x = (0, x_2, x_3)$ é um vetor qualquer em Σ_{yz} então para $v = (v_1, 0, 0) \in S_1$ temos $\langle x, v \rangle = 0 \cdot v_1 + x_2 \cdot 0 + x_3 \cdot 0 = 0$. Como v foi escolhido arbitrariamente em S_1 , temos que x está em $S_1^\perp$. Logo, todo vetor no plano yz pertence a $S_1^\perp$ e assim o plano yz está contido em $S_1^\perp$. Em linguagem de conjuntos, acabamos de verificar que $\forall x \in \Sigma_{yz}, x \in S_1^\perp$ logo $\Sigma_{yz} \subset S_1^\perp$.
- (2) Agora, tome $w = (w_1, w_2, w_3) \in S_1^\perp$. Então, $w \perp x$ para todo $x \in S_1$. Em particular, podemos testar esta relação para uma base de S_1 . Tomando $x = e_1 = (1, 0, 0)$ temos que $0 = \langle w, e_1 \rangle = w_1$. Portanto $w_1 = 0$ e assim w pertence a Σ_{yz} . Concluimos assim que todo vetor em $S_1^\perp$ está em Σ_{yz} logo $S_1^\perp \subset \Sigma_{yz}$.

Finalmente, acabamos de ver que $S_1^\perp \subset \Sigma_{yz}$ e $\Sigma_{yz} \subset S_1^\perp$ então estes conjuntos são iguais: $\Sigma_{yz} = S_1^\perp$.

Exercício 3. Sejam Σ_{yz} e S_1 como acima. Verifique que $\Sigma_{yz}^\perp = S_1$.

Exercício 4. Para S_2 e S_3 como acima, encontre (com justificativa) $S_2^\perp$ e $S_3^\perp$.

Exemplo 18. Seja $A = \begin{pmatrix} 1 & 3 \\ 2 & 6 \\ 3 & 9 \end{pmatrix}$.

- (a) Encontre uma base para o espaço-linha de A .
- (b) Encontre o espaço nulo de A .
- (c) Encontre $[C(A^T)]^\perp$.
- (d) Encontre $[N(A)]^\perp$.

Solução. (a) Com as operações $\ell_2 \rightarrow \ell_2 - 2\ell_1$ e $\ell_3 \rightarrow \ell_3 - 3\ell_1$ vemos que uma forma escalonada de A é $U = \begin{pmatrix} 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}$. Daí segue imediatamente que seu espaço linha é

a reta $C(A^T) = \text{Ger}\left\{\begin{pmatrix} 1 \\ 3 \end{pmatrix}\right\}$.

- (b) $N(A)$ pode ser calculado através da relação $x \in N(A) \iff Ux = 0$. Ou seja, $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in N(A)$ exatamente quando $\langle \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rangle = 0$, ou seja, quando $x_1 + 3x_2 = 0$. Logo

$$N(A) = \text{Ger}\left\{\begin{pmatrix} -3 \\ 1 \end{pmatrix}\right\}.$$

- (c) Ora, $v = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ é ortogonal ao espaço linha de A exatamente quando $v \perp \begin{pmatrix} 1 \\ 3 \end{pmatrix}$, pois este vetor é uma base para espaço linha de A . Assim, $v \in [C(A^T)]^\perp \iff \langle v, \begin{pmatrix} 1 \\ 3 \end{pmatrix} \rangle = 0$. Em particular, isto é o que foi calculado no exemplo acima e vemos que $[C(A^T)]^\perp = N(A)$.

- (d) Partindo do item (b), $N(A) = \text{Ger}\left\{\begin{pmatrix} -3 \\ 1 \end{pmatrix}\right\}$. Assim, $w = \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} \in [N(A)]^\perp$ se e somente se $\langle w, \begin{pmatrix} -3 \\ 1 \end{pmatrix} \rangle = 0$, ou seja se $w_2 = 3w_1$. Mas isto significa que $w = w_1 \begin{pmatrix} 1 \\ 3 \end{pmatrix} \in \text{Ger}\left\{\begin{pmatrix} 1 \\ 3 \end{pmatrix}\right\}$. Temos imediatamente pelo item (a) que $[N(A)]^\perp = C(A^T)$. □

O que ocorre no exemplo anterior não é obra do acaso:

Teorema 4. (*Teorema fundamental da ortogonalidade*) Seja $A_{m \times n}$ uma matriz $m \times n$. Então o espaço nulo de A é o complemento ortogonal do espaço linha de A em $\mathbb{R}^n$: $N(A) = [C(A^T)]^\perp$.

Observação 11. Lembrando que o posto de A é a dimensão de seu espaço linha, segue que $(\text{posto de } A) + \dim N(A) = \text{número de colunas de } A$. Esta é a versão mais simples do Teorema do núcleo e da imagem.

3.1. Projeções ortogonais.

Definição 16. *Sejam u e v vetores em $\mathbb{R}^n$ com $v \neq \vec{0}$. A projeção de u sobre v é o vetor*

$$P_v(u) = \frac{\langle u, v \rangle}{|v|^2} v.$$

A constante $\alpha = \frac{\langle u, v \rangle}{|v|^2}$ é chamada a projeção escalar de u sobre v .

Observação 12. $P_v(u)$ também é dita a projeção de u sobre a reta $\{tv, t \in \mathbb{R}\}$.

Proposição 5. *(Propriedades da projeção)*

- (a) Se u é um vetor na direção de v então $P_v(u) = u$.
- (b) $P_v(u)$ é um vetor na direção de v .
- (c) $u - P_v(u) \perp v$.
- (d) $u - P_v(u) \perp P_v(u)$.
- (e) $|P_v(u)| \leq |u|$, com igualdade se e somente se u é um vetor na direção de v .

Demonstração. (a) Se $u = tv$ então $P_v(u) = \frac{\langle tv, v \rangle}{|v|^2} v = tv = u$.

(b) Segue diretamente da definição.

(c) Seja $\alpha = \frac{\langle u, v \rangle}{|v|^2}$ de modo que $P_v(u) = \alpha v$. Então pelas propriedades do produto interno:

$$\begin{aligned} \langle u - P_v(u), v \rangle &= \langle u, v \rangle - \langle P_v(u), v \rangle \\ &= \langle u, v \rangle - \langle \alpha v, v \rangle \\ &= \langle u, v \rangle - \alpha \langle v, v \rangle \\ &= \langle u, v \rangle - \frac{\langle u, v \rangle}{|v|^2} \langle v, v \rangle \\ &= 0. \end{aligned}$$

(d) Isto segue das duas propriedades anteriores.

(e) Escrevendo $u = P_v(u) + (u - P_v(u))$ e usando que $(u - P_v(u)) \perp P_v(u)$ temos, pelo teorema de Pitágoras, que

$$|u|^2 = |P_v(u)|^2 + |u - P_v(u)|^2.$$

Em particular, $|P_v(u)|^2 \leq |u|^2$, ou seja, $|P_v(u)| \leq |u|$ como queríamos mostrar. Note que a igualdade ocorre quando $u - P_v(u) = 0$, ou seja, quando u é um vetor na direção de v .

□

Teorema 5. *(Desigualdade de Cauchy-Schwarz) Sejam $u, v \in \mathbb{R}^n$. Então*

$$|\langle u, v \rangle| \leq |u||v|,$$

com igualdade se e somente se u é um vetor na direção de v .

Demonstração. Se $v = \vec{0}$ não há nada a mostrar. Em outro caso, usando $|P_v(u)| \leq |u|$ obtemos

$$\frac{|\langle u, v \rangle||v|}{|v|^2} \leq |u|,$$

ou seja $|\langle u, v \rangle| \leq \|u\| \|v\|$.

□

Exemplo 19. Sejam $u = \begin{pmatrix} -1 \\ 0 \\ 2 \end{pmatrix}$ e $v = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$. Calcule $P_v(u)$, verifique explicitamente que $u - P_v(u) \perp v$ e escreva a desigualdade de Cauchy-Schwarz nesse caso.

Solução. $\langle u, v \rangle = -1 + 0 + 4 = 3$ e $|v|^2 = 1^2 + 2^2 + 2^2 = 9$ logo $P_v(u) = \frac{3}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 1/3 \\ 2/3 \\ 2/3 \end{pmatrix}$. Assim $u - P_v(u) = \begin{pmatrix} -4/3 \\ -2/3 \\ 4/3 \end{pmatrix}$ daí $\langle u - P_v(u), v \rangle = -4/3 - 4/3 + 8/3 = 0$ portanto $u - P_v(u) \perp v$. Como $|u|^2 = (-1)^2 + 0^2 + 2^2 = 5$ a desigualdade de Cauchy-Schwarz nesse caso é $3 \leq \sqrt{5}\sqrt{9} = 3\sqrt{5}$. □

Proposição 6. Fixe $v \neq \vec{0}$ em $\mathbb{R}^n$. A transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^n$ dada por $T(u) = P_v(u)$ é uma transformação linear.

Demonstração. Dados $\alpha, \beta \in \mathbb{R}$ e u_1, u_2 em $\mathbb{R}^n$,

$$\begin{aligned} T(\alpha u_1 + \beta u_2) &= P_v(\alpha u_1 + \beta u_2) \\ &= \frac{\langle \alpha u_1 + \beta u_2, v \rangle}{|v|^2} v \\ &= \frac{\langle \alpha u_1, v \rangle}{|v|^2} v + \frac{\langle \beta u_2, v \rangle}{|v|^2} v \\ &= \alpha \frac{\langle u_1, v \rangle}{|v|^2} v + \beta \frac{\langle u_2, v \rangle}{|v|^2} v \\ &= \alpha T(u_1) + \beta T(u_2). \end{aligned}$$

□

Exemplo 20. Seja $v = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$. Vamos encontrar uma fórmula para a transformação linear

acima. Se $x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \in \mathbb{R}^3$, então $\langle x, v \rangle = x_1 + 2x_2 + 2x_3$. Usando que $|v|^2 = 9$ concluímos que

$$T(x) = P_v(x) = \frac{x_1 + 2x_2 + 2x_3}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

Vale a pena examinar alguns casos particulares da fórmula acima. Se $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = v$

então $T(x) = T(v) = \frac{9}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = v$, como esperado. Mais geralmente, se $w = tv$ para algum

$t \in \mathbb{R}$, $T(w) = \frac{9t}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = tv = w$. Por outro lado, se $x = \begin{pmatrix} -1 \\ 1/2 \\ 0 \end{pmatrix}$ e $y = \begin{pmatrix} 4 \\ -1 \\ -1 \end{pmatrix}$ vemos que

$$T(x) = \frac{-1+1}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = 0,$$

$$T(y) = \frac{4-2-2}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = 0.$$

Deixamos a cargo do leitor encontrar um sentido geométrico para estes resultados.

Como toda transformação linear, $u \mapsto T(u) = P_v(u)$ possui uma representação matricial com respeito à base canônica de $\mathbb{R}^n$. Para encontrar a matriz de T , calculamos, para $j = 1, 2, \dots, n$, $e_1 = (1, 0, \dots, 0), \dots, e_n = (0, 0, \dots, 0, 1)$,

$$T(e_j) = P_v(e_j) = \frac{v_j}{|v|^2} v.$$

Logo, a matriz de T com respeito à base canônica de $\mathbb{R}^n$ é

$$\left(\frac{v_1}{|v|^2} v, \dots, \frac{v_n}{|v|^2} v \right)_{n \times n}.$$

Observação 13. Observe que se $v = \begin{pmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{pmatrix}$ então

$$\begin{aligned} vv^T &= \begin{pmatrix} v_1^2 & v_1 v_2 & \dots & v_1 v_n \\ v_2 v_1 & v_2^2 & \dots & v_2 v_n \\ \dots & \dots & \dots & \dots \\ v_n v_1 & v_n v_2 & \dots & v_n^2 \end{pmatrix} \\ &= (v_1 v, \dots, v_n v)_{n \times n}. \end{aligned}$$

Assim, a matriz de projeção pode ser expressa simplesmente por $P = \frac{vv^T}{|v|^2}$.

Exemplo 21. Seja $v = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$. Então

$$\begin{aligned} vv^T &= \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \begin{pmatrix} 1 & 2 & 2 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{pmatrix} \end{aligned}$$

Assim a matriz de projeção é

$$P = \frac{1}{9} \begin{pmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{pmatrix}.$$

Se $x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \in \mathbb{R}^3$, calculamos

$$Px = \frac{1}{9} \begin{pmatrix} x_1 + 2x_2 + 2x_3 \\ 2x_1 + 4x_2 + 4x_3 \\ 2x_1 + 4x_2 + 4x_3 \end{pmatrix}.$$

Note que esta é uma maneira alternativa de obter a fórmula do exemplo 20 para $T(x)$.

3.2. Exercícios sobre projeções.

Exemplo 22. Seja P a matriz de projeção sobre um vetor em $\mathbb{R}^n$. Verdadeiro ou falso?

(a) $(I + P)^2 = I + 3P$

(b) $P(I - P) = 0$

(c) $(A + P)^2 = A^2 + 2AP + P$ para toda matriz $A_{n \times n}$.

Solução. (a) **V.**

$$\begin{aligned} (I + P)^2 &= (I + P)(I + P) \\ &= I^2 + IP + PI + P^2 \\ &= I + 2P + P^2 \\ &= I + 3P \end{aligned}$$

(b) **V.** $P(I - P) = PI - P^2 = P - P^2 = 0$.

(c) **F.**

$$\begin{aligned}(A + P)^2 &= (A + P)(A + P) \\ &= A^2 + AP + PA + P^2 \\ &= A^2 + AP + PA + P\end{aligned}$$

mas em geral não é verdade que $AP = PA$. Por exemplo, se $n = 2$ e P é a projeção sobre $e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ então $P = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ assim $P \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a & b \\ 0 & 0 \end{pmatrix}$ enquanto $\begin{pmatrix} a & b \\ c & d \end{pmatrix} P = \begin{pmatrix} a & 0 \\ c & 0 \end{pmatrix}$.

□

Exemplo 23. Sejam $v_1 = \begin{pmatrix} 1 \\ 0 \\ 1 \\ 0 \end{pmatrix}$ e $v_2 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}$ encontre um vetor $w \in \mathbb{R}^4$ tal que $w \perp v_1$ e

$$\text{Ger}\{v_1, w\} = \text{Ger}\{v_1, v_2\}.$$

Solução. Tome $w = v_2 - P_{v_1}(v_2)$. Então $\langle v_2, v_1 \rangle = 2$ e $|v_1|^2 = 2$ logo $P_{v_1}(v_2) = v_1$ e assim

$$w = v_2 - v_1 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 1 \end{pmatrix}.$$

Com essa escolha, sabemos da teoria que $w \perp v_1$. Além disso,

$$\begin{aligned}\text{Ger}\{v_1, w\} &= \{\alpha v_1 + \beta w : \alpha, \beta \in \mathbb{R}\} \\ &= \left\{ \begin{pmatrix} \alpha \\ \beta \\ \alpha \\ \beta \end{pmatrix} : \alpha, \beta \in \mathbb{R} \right\}.\end{aligned}$$

Similarmente,

$$\begin{aligned}\text{Ger}\{v_1, v_2\} &= \{tv_1 + sv_2 : t, s \in \mathbb{R}\} \\ &= \left\{ \begin{pmatrix} t + s \\ s \\ t + s \\ s \end{pmatrix} : t, s \in \mathbb{R} \right\}.\end{aligned}$$

Fazendo $t' = t + s$ vemos que os conjuntos acima são iguais.

□

Exemplo 24. Sejam u e v vetores em $\mathbb{R}^n$. Calcule $\langle u + v, u + v \rangle$ e conclua que $|u + v| \leq |u| + |v|$. Quando ocorre a igualdade?

Solução.

$$\begin{aligned}
 |u + v|^2 &= \langle u + v, u + v \rangle \\
 &= |u|^2 + 2\langle u, v \rangle + |v|^2 \\
 &\leq |u|^2 + 2|u||v| + |v|^2 \\
 &= (|u| + |v|)^2
 \end{aligned}$$

onde no penúltimo passo usamos a desigualdade de Cauchy-Schwarz. Concluimos então que $|u + v| \leq |u| + |v|$ com igualdade se, e somente se, os vetores u e v são linearmente dependentes. □

Exemplo 25. *Sejam u e v vetores em $\mathbb{R}^4$ com $|u| = 4$ e $|v| = 10$. Qual o maior valor que $\langle u, v \rangle$ pode tomar? Dê exemplos de vetores onde esta valor é atingido.*

Solução. Por Cauchy-Schwarz $|\langle u, v \rangle| \leq |u||v| = 40$. Assim o maior valor possível é 40 caso

os vetores sejam paralelos. Por exemplo os pares $u = \begin{pmatrix} 4 \\ 0 \\ 0 \\ 0 \end{pmatrix}$ e $v = \begin{pmatrix} 10 \\ 0 \\ 0 \\ 0 \end{pmatrix}$ ou

$\tilde{u} = \begin{pmatrix} 2 \\ 2 \\ 2 \\ 2 \end{pmatrix}$ e $\tilde{v} = \begin{pmatrix} 5 \\ 5 \\ 5 \\ 5 \end{pmatrix}$ são tais que $\langle u, v \rangle$ e $\langle \tilde{u}, \tilde{v} \rangle$ atingem estes valores. □

Exemplo 26. *Calcule as matrizes de projeção sobre os vetores $v = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$ e $w = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix}$. O que pode ser dito sobre o traço (ou seja, a soma das entradas da diagonal) destas matrizes?*

Solução. $|v|^2 = 2$ e $vv^T = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & 0 & 1 \end{pmatrix}$ assim $P_v = \begin{pmatrix} 1/2 & 0 & 1/2 \\ 0 & 0 & 0 \\ 1/2 & 0 & 1/2 \end{pmatrix}$. Note que o traço de P é $\text{Tr}(P) = 1/2 + 0 + 1/2 = 1$. Por outro lado,

$|w|^2 = 25$ e $ww^T = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 9 & 12 \\ 0 & 12 & 16 \end{pmatrix}$ assim $P_w = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 9/25 & 12/25 \\ 0 & 12/25 & 16/25 \end{pmatrix}$. Note que o traço de P_w é $\text{Tr}(w) = 0 + 9/25 + 16/25 = 1$. □

4. PROJEÇÕES SOBRE SUBESPAÇOS

Exemplo 27. Encontre a melhor aproximação linear para a tabela a seguir, onde o tempo negativo pode ser interpretado como tempo passado.

$t=\text{tempo}$	$b(t)=\text{resultado}$
-1	1
1	1
2	3

Caso os pontos $(-1, 1)$, $(1, 1)$ e $(2, 3)$ estivessem alinhados, digamos na reta $\ell(t) = C + Dt$, haveria uma solução exata para o sistema

$$\begin{pmatrix} 1 & -1 \\ 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}.$$

Como estes pontos não estão alinhados, este sistema não possui solução e assim vamos ter que encontrar a melhor “solução aproximada”. Para tal, desenvolvemos um pouco de teoria a seguir.

Suponha que $Ax = b$ seja um sistema linear inconsistente. Uma pergunta natural é a seguinte: como minimizar o “erro” $Ax - b$? A primeira coisa a fazer é interpretar Ax como um vetor no espaço coluna de A .

Exemplo 28. Seja $A = \begin{pmatrix} 1 & -1 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$. Dado $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ então

$$Ax = \begin{pmatrix} x_1 - x_2 \\ x_1 + x_2 \\ x_1 + 2x_2 \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} + x_2 \begin{pmatrix} -1 \\ 1 \\ 2 \end{pmatrix}.$$

Mais geralmente, se A é uma matriz $m \times n$ e $A_1, \dots, A_n$ são seus vetores coluna então para cada $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ vale que $Ax = x_1 A_1 + \dots + x_n A_n$. Em particular $Ax \in C(A)$.

Voltando à nossa pergunta, faz sentido tentar minimizar o comprimento $|Ax - b|$. Pelo exemplo acima isto equivale a encontrar a distância (mínima) entre b e $C(A)$. Deste modo, o minimizante $\hat{x}$ deve ser tal que $b - A\hat{x} \perp C(A)$, ou seja, $b - A\hat{x} \in N(A^T)$. Daí, encontramos que $A^T(b - A\hat{x}) = 0$ ou seja

$$(8) \quad A^T A \hat{x} = A^T b.$$

As equações que compõem o sistema de acima são ditas as equações normais associadas a $Ax = b$. Caso $A^T A$ seja uma matriz invertível, o sistema (8) admite solução única, a saber

$$(9) \quad \hat{x} = (A^T A)^{-1} A^T b.$$

Em particular, o ponto em $C(A)$ mais próximo de b é

$$(10) \quad A\hat{x} = A(A^T A)^{-1} A^T b.$$

Solução do exemplo 27. Sejam $A = \begin{pmatrix} 1 & -1 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$, $x = \begin{pmatrix} C \\ D \end{pmatrix}$ e $b = \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}$. Então

$A^T A = \begin{pmatrix} 3 & 2 \\ 2 & 6 \end{pmatrix}$ e $A^T b = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$. Assim, o minimizante $\hat{x} = \begin{pmatrix} \hat{C} \\ \hat{D} \end{pmatrix}$ resolve

$$\begin{pmatrix} 3 & 2 \\ 2 & 6 \end{pmatrix} \begin{pmatrix} \hat{C} \\ \hat{D} \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}.$$

Portanto

$$\begin{aligned} \begin{pmatrix} \hat{C} \\ \hat{D} \end{pmatrix} &= \begin{pmatrix} 3 & 2 \\ 2 & 6 \end{pmatrix}^{-1} \begin{pmatrix} 5 \\ 6 \end{pmatrix} \\ &= \frac{1}{14} \begin{pmatrix} 6 & -2 \\ -2 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \end{pmatrix} \\ &= \begin{pmatrix} 9/7 \\ 4/7 \end{pmatrix}. \end{aligned}$$

Assim, a melhor aproximação linear para o problema estudado é a reta $\ell(t) = 9/7 + 4/7t$.

Note que calculando $A\hat{x} = \begin{pmatrix} 5/7 \\ 13/7 \\ 17/7 \end{pmatrix}$ obtemos a projeção de b sobre $C(A)$ e que os pontos $(-1, 5/7)$, $(1, 13/7)$ e $(2, 17/7)$ pertencem à reta $\ell(t)$.

□

Exemplo 29. Sejam $A = \begin{pmatrix} 1 & 2 \\ 1 & 3 \\ 0 & 0 \end{pmatrix}$ e $b = \begin{pmatrix} 4 \\ 5 \\ 6 \end{pmatrix}$. Dado $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ lembre que $Ax =$

$\begin{pmatrix} x_1 + 2x_2 \\ x_1 + 3x_2 \\ 0 \end{pmatrix}$ logo $Ax = b$ não possui solução. Intuitivamente, o ponto mais próximo de b

em $C(A)$ é $\begin{pmatrix} 4 \\ 5 \\ 0 \end{pmatrix}$. Vamos verificar isto usando o sistema de equações normais. Fica como

exercício verificar que $A^T A = \begin{pmatrix} 2 & 5 \\ 5 & 13 \end{pmatrix}$ e esta matriz tem inversa $(A^T A)^{-1} = \begin{pmatrix} 13 & -5 \\ -5 & 2 \end{pmatrix}$.

Portanto utilizando as fórmulas (9) e (10) concluímos que $\hat{x} = \begin{pmatrix} 13 & -5 \\ -5 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 2 & 3 & 0 \end{pmatrix} \begin{pmatrix} 4 \\ 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ e $A\hat{x} = \begin{pmatrix} 1 & 2 \\ 1 & 3 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 5 \\ 0 \end{pmatrix}$.

Definição 17. Suponha que $A^T A$ seja invertível. O vetor $P_{C(A)}(b) = A(A^T A)^{-1} A^T b$ é dito a projeção de b sobre o espaço coluna de A .

Façamos agora algumas observações.

Proposição 7. No contexto da definição 17 temos o seguinte.

- (a) Se $b \in C(A)$ então $P_{C(A)}(b) = b$.
- (b) Se $b \in N(A^T)$ então $P_{C(A)}(b) = \vec{0}$.
- (c) Se A é uma matriz invertível $m \times m$ então $P_{C(A)}(b) = b$ para todo b em $\mathbb{R}^m$.
- (d) Se v é um vetor em $\mathbb{R}^m$, então $P_{C(v)}(b) = P_v(b)$ para todo b em $\mathbb{R}^m$.

Demonstração. (a) Caso $b = Aw$ para algum w , ou seja se $b \in C(A)$, então

$$\begin{aligned} P_{C(A)}(b) &= A(A^T A)^{-1} A^T b \\ &= A(A^T A)^{-1} A^T Aw \\ &= Aw \\ &= b \end{aligned}$$

Ou seja, b é a sua própria projeção.

- (b) Se $b \in N(A^T)$ então $b \in [C(A)]^\perp$ logo $P_{C(A)}(b) = A(A^T A)^{-1} A^T b = \vec{0}$.
- (c) Caso A seja uma matriz quadrada e invertível, então A^T também é invertível e $(A^T A)^{-1} = A^{-1}(A^T)^{-1}$. Assim, $P_{C(A)}(b) = A(A^T A)^{-1} A^T b = AA^{-1}(A^T)^{-1} A^T b = b$.
- (d) Se $v = v_{m \times 1}$ é um vetor em $\mathbb{R}^m$ e $b \in \mathbb{R}^m$ então $v^T v$ é igual a $|v|^2$. Mais geralmente $v^T b = \langle v, b \rangle$ também é um número real, logo $P_{C(v)}(b) = v(v^T v)^{-1} v^T b = \frac{\langle v, b \rangle}{|v|^2} v$ coincide com a projeção de b sobre v , como esperado.

□

Agora vamos buscar condições que tornem $A^T A$ invertível. Primeiro devemos entender como a transposição interage com o produto interno.

Exemplo 30. Sejam $A = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$, $v = \begin{pmatrix} 30 \\ 20 \\ 10 \end{pmatrix}$ e $u = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. Calcule $\langle u, A^T v \rangle_{\mathbb{R}^2}$ e $\langle Au, v \rangle_{\mathbb{R}^3}$.

Solução.

$$\begin{aligned} A^T v &= \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \begin{pmatrix} 30 \\ 20 \\ 10 \end{pmatrix} \\ &= \begin{pmatrix} 100 \\ 280 \end{pmatrix}. \end{aligned}$$

Logo $\langle A^T v, u \rangle = 100 + 280 = 380$. Por outro lado,

$$\begin{aligned} Au &= \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= \begin{pmatrix} 5 \\ 7 \\ 9 \end{pmatrix}. \end{aligned}$$

Portanto $\langle Au, v \rangle_{\mathbb{R}^3} = 5 \cdot 30 + 7 \cdot 20 + 9 \cdot 10 = 380$. □

Por trás deste exemplo há o seguinte fato geral:

Proposição 8. *Sejam A uma matriz $m \times n$, $v \in \mathbb{R}^m$ e $u \in \mathbb{R}^n$. Então*

$$\langle Au, v \rangle_{\mathbb{R}^m} = \langle u, A^T v \rangle_{\mathbb{R}^n}.$$

Demonstração.

$$\begin{aligned} \langle u, A^T v \rangle_{\mathbb{R}^n} &= \sum_{i=1}^n u_i (A^T v)_i \\ &= \sum_{i=1}^n u_i \sum_{k=1}^m A_{ik}^T v_k \\ &= \sum_{i=1}^n u_i \sum_{k=1}^m A_{ki} v_k \\ &= \sum_{k=1}^m v_k \left(\sum_{i=1}^n u_i A_{ki} \right) \\ &= \sum_{k=1}^m v_k (Au)_k \\ &= \langle Au, v \rangle_{\mathbb{R}^m}. \end{aligned}$$

□

Agora estamos preparados para enunciar o seguinte.

Proposição 9. *Seja A uma matriz $m \times n$. Então*

- (a) $N(A^T A) = N(A)$.
 (b) As colunas de A são linearmente independentes se e somente se $A^T A$ é invertível.

Demonstração. (a) Primeiro verificamos a inclusão $N(A) \subset N(A^T A)$. Se $x \in N(A)$, então $A^T Ax = A^T \vec{0} = \vec{0}$ logo $x \in N(A^T A)$ e assim $N(A) \subset N(A^T A)$.

Agora queremos ver que $N(A^T A) \subset N(A)$. Se $y \in N(A^T A)$ observe que pela proposição 8

$$\langle Ay, Ay \rangle = \langle y, A^T Ay \rangle = 0.$$

Deste modo, provamos que $|Ay|^2 = 0$ e assim $Ay = \vec{0}$ da onde segue que $y \in N(A)$. Portanto $N(A^T A) \subset N(A)$ vale também e assim $N(A^T A) = N(A)$.

- (b) $A_{m \times n}$ tem n colunas linearmente independentes se e somente se A tem posto n , o que equivale a dizer que $\dim N(A) = 0$. Pelo item anterior, $\dim N(A) = 0 \iff \dim N(A^T A) = 0$. Mas $A^T A$ é uma matriz quadrada $n \times n$ e logo esta matriz tem posto n se e somente se $\dim N(A^T A) = 0$ e, neste caso, $A^T A$ é invertível. $\square$

5. CONJUNTOS ORTONORMAIS

Definição 18. Um conjunto de vetores **não-nulos** $\{v_1, \dots, v_m\}$ em $\mathbb{R}^n$ é dito **ortogonal** quando $\langle v_i, v_j \rangle = 0$ se $i \neq j$ para $i, j \in \{1, \dots, m\}$.

Exemplo 31. Os conjuntos $\left\{ \begin{pmatrix} 5 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -4 \\ 0 \end{pmatrix} \right\}$ e $\left\{ \begin{pmatrix} 5 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ -4 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ -5 \end{pmatrix} \right\}$ são ambos conjuntos ortogonais em $\mathbb{R}^3$.

Exemplo 32. O conjunto $\left\{ \begin{pmatrix} 5 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ -4 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ -5 \end{pmatrix} \right\}$ não é um conjunto ortogonal.

Definição 19. Um conjunto de vetores **não-nulos** $\{u_1, \dots, u_m\}$ em $\mathbb{R}^n$ é dito **ortonormal** quando

- (a) $\{u_1, \dots, u_m\}$ é um conjunto ortogonal.
 (b) $|u_j| = 1$ para todo $j \in \{1, \dots, m\}$.

Exemplo 33. Os conjuntos $\left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 0 \end{pmatrix} \right\}$ e $\left\{ \frac{1}{\sqrt{26}} \begin{pmatrix} 5 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 0 \end{pmatrix}, \frac{1}{\sqrt{26}} \begin{pmatrix} 1 \\ 0 \\ -5 \end{pmatrix} \right\}$ são ambos conjuntos ortonormais em $\mathbb{R}^3$.

Exemplo 34. Seja $\{u_1, \dots, u_m\}$ um conjunto ortonormal e defina $U = \text{Ger}\{u_1, \dots, u_m\}$. Vejamos um modo alternativo de calcular a projeção $\vec{p} = P_U(b)$ de um vetor b sobre U sem fazer uso de matrizes. Note que $\vec{p}$ satisfaz duas premissas. Primeiro, deve ser um vetor em U , logo $p = \alpha_1 u_1 + \dots + \alpha_m u_m$. Segundo, devemos ter $b - p \perp U$. Assim para cada

$$j \in \{1, \dots, m\}$$

$$\begin{aligned} \langle b - p, u_j \rangle &= \langle b - \sum_{i=1}^m \alpha_i u_i, u_j \rangle \\ &= \langle b, u_j \rangle - \sum_{i=1}^m \alpha_i \langle u_i, u_j \rangle \\ &= \langle b, u_j \rangle - \alpha_j \langle u_j, u_j \rangle \\ &= \langle b, u_j \rangle - \alpha_j. \end{aligned}$$

Em particular, queremos $\alpha_j = \langle b, u_j \rangle$. Desta forma, **neste caso**,

$$P_U(b) = \sum_{i=1}^m \langle b, u_i \rangle u_i.$$

Exemplo 35. Se $\{u_1, u_2\} = \left\{ \frac{1}{\sqrt{26}} \begin{pmatrix} 5 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\}$ então a projeção do vetor $b = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix}$ sobre $U = \text{Ger}\{u_1, u_2\}$ é $P_U(b) = \frac{4}{\sqrt{26}} \begin{pmatrix} 5 \\ 0 \\ 1 \end{pmatrix} + 3 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$.

5.1. O processo de Gram-Schmidt e a fatoração $A = QR$. Dado um conjunto $\{v_1, v_2, v_3\}$, de vetores linearmente independentes em $\mathbb{R}^n$, aplicando o processo de Gram-Schmidt,

$$\begin{aligned} q_1 &= \frac{v_1}{|v_1|} \\ q_2 &= \frac{v_2 - P_{q_1}(v_2)}{|v_2 - P_{q_1}(v_2)|} \\ q_3 &= \frac{v_3 - P_{q_1}(v_3) - P_{q_2}(v_3)}{|v_3 - P_{q_1}(v_3) - P_{q_2}(v_3)|}, \end{aligned}$$

obtemos o conjunto ortonormal $\{q_1, q_2, q_3\}$. Lembramos que neste processo $v_1 \in \text{Ger}\{q_1\}$, $v_2 \in \text{Ger}\{q_1, q_2\}$ e $v_3 \in \text{Ger}\{q_1, q_2, q_3\}$. Escrevendo

$$\begin{cases} v_1 = \alpha_{11}q_1 \\ v_2 = \alpha_{21}q_1 + \alpha_{22}q_2 \\ v_3 = \alpha_{31}q_1 + \alpha_{32}q_2 + \alpha_{33}q_3 \end{cases}$$

e tomando produtos internos com os vetores q_1, q_2 e q_3 concluímos que $\alpha_{ij} = \langle v_i, q_j \rangle$, ou seja, $\alpha_{11} = \langle v_1, q_1 \rangle$, $\alpha_{21} = \langle v_2, q_1 \rangle$, $\alpha_{22} = \langle v_2, q_2 \rangle$, $\alpha_{31} = \langle v_3, q_1 \rangle$, $\alpha_{32} = \langle v_3, q_2 \rangle$, $\alpha_{33} = \langle v_3, q_3 \rangle$. Deste modo,

$$(11) \quad \begin{pmatrix} v_1 & v_2 & v_3 \end{pmatrix} = \begin{pmatrix} q_1 & q_2 & q_3 \end{pmatrix} \begin{pmatrix} \langle v_1, q_1 \rangle & \langle v_2, q_1 \rangle & \langle v_3, q_1 \rangle \\ 0 & \langle v_2, q_2 \rangle & \langle v_3, q_2 \rangle \\ 0 & 0 & \langle v_3, q_3 \rangle \end{pmatrix} = QR.$$

Exercício 5. Dados $\{v_1, v_2, v_3\} = \left\{ \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 3 \end{pmatrix} \right\}$, verifique que aplicando o pro-

cesso de Gram-Schmidt obtemos o conjunto ortonormal $\{q_1, q_2, q_3\} = \left\{ \begin{pmatrix} 1/3 \\ 2/3 \\ 2/3 \end{pmatrix}, \begin{pmatrix} -2/3 \\ -1/3 \\ 2/3 \end{pmatrix}, \begin{pmatrix} 2/3 \\ -2/3 \\ 1/3 \end{pmatrix} \right\}$.

A partir do exemplo acima é fácil calcular $R = \begin{pmatrix} 3 & 1 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 1 \end{pmatrix}$ e assim concluir que

$$\begin{pmatrix} 1 & -1 & 0 \\ 2 & 0 & 0 \\ 2 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \\ 2/3 & 2/3 & 1/3 \end{pmatrix} \begin{pmatrix} 3 & 1 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 1 \end{pmatrix}.$$

Motivados por isso colocamos as seguintes definições:

Definição 20. Uma matriz $Q_{m \times n}$ é dita ortogonal quando suas colunas são vetores ortonormais em $\mathbb{R}^m$.

Definição 21. Um matriz $A_{m \times n}$ está fatorada na forma $A = QR$ quando Q é uma matriz ortogonal e R é uma matriz triangular superior.

5.2. Aplicações da fatoração $A = QR$.

Proposição 10. Seja $Q_{m \times n}$ uma matriz ortogonal. Então $Q^T Q = I_{n \times n}$.

Demonstração. Vamos denotar $Q = (Q_1, \dots, Q_n)$ onde $Q_1, \dots, Q_n$ são vetores coluna em $\mathbb{R}^m$.

$$\begin{aligned} (Q^T Q)_{ij} &= \sum_{k=1}^m Q_{ik}^T Q_{kj} \\ &= \sum_{k=1}^m Q_{ki} Q_{kj} \\ &= \langle Q_i, Q_j \rangle \\ &= \delta_{ij}, \end{aligned}$$

onde escrevemos $\delta_{ij} = 1$ se $i = j$ e $\delta_{ij} = 0$ se $i \neq j$. Em particular, $Q^T Q = I$. □

Suponha agora que $A = QR$ com Q uma matriz ortogonal. Então

$$A^T A = (QR)^T (QR) = R^T Q^T QR = R^T I R = R^T R.$$

Assim, o sistema de equações normais $A^T A \hat{x} = A^T b$ é equivalente a $R^T R \hat{x} = R^T Q^T b$. Assim, caso R^T seja invertível, temos

$$A^T A x = A^T b \iff R \hat{x} = Q^T b.$$

Exemplo 36. *Seja*

$$\begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$$

a fatoração $A = QR$ de $A = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$. Se $b = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$ o sistema $Ax = b$ não possui

solução. Como R é quadrada e invertível, nesse caso R^T é invertível e podemos encontrar a melhor solução aproximada resolvendo $R\hat{x} = Q^T b$, ou seja,

$$\begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \hat{x}_1 \\ \hat{x}_2 \\ \hat{x}_3 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

Daí, concluímos facilmente que $\begin{pmatrix} \hat{x}_1 \\ \hat{x}_2 \\ \hat{x}_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$.

6. NORMAS VETORIAIS E MATRICIAIS

Definição 22. *Seja E um espaço vetorial real. Uma norma em E é uma função $\|\cdot\| : E \rightarrow \mathbb{R}$ tal que*

- (i) $\|x\| \geq 0$ para todo $x \in E$ e $\|x\| = 0$ se, e somente se, $x = \vec{0}$.
- (ii) $\|\lambda x\| = |\lambda| \|x\|$, para todo $x \in E$ e $\lambda \in \mathbb{R}$.
- (iii) $\|x + y\| \leq \|x\| + \|y\|$, para todos $x \in E$ e $y \in E$.

Exemplo 37. *Várias normas diferentes podem ser definidas em $\mathbb{R}^n$, por exemplo, se de-*

notamos $x = \begin{pmatrix} x_1 \\ \dots \\ x_n \end{pmatrix}$:

- (a) $|x| = \sqrt{x_1^2 + \dots + x_n^2}$ é a norma Euclidiana de x
- (b) $|x|_\infty = \max\{|x_j| : j = 1, \dots, n\}$ é a norma do máximo de x .
- (c) $|x|_1 = |x_1| + \dots + |x_n|$ é a norma da soma de x .
- (d) Mais geralmente, se $p \geq 1$, $|x|_p = (|x_1|^p + \dots + |x_n|^p)^{1/p}$ é a p -norma de x .

Já verificamos anteriormente que a norma Euclidiana satisfaz as condições da definição 22. É deixado como exercício verificar que $|\cdot|_\infty$ e $|\cdot|_1$ de fato definem normas. A norma $|\cdot|_p$ para $p > 1$ arbitrário necessita de maior esforço e, no momento, foge aos objetivos do curso. Observamos apenas que no caso $p = 2$ $|x|_p$ coincide com a norma Euclidiana de x .

Exemplo 38. *Verifique que existem C_1 e C_2 tais que as desigualdades $|x|_\infty \leq C_1 |x|_1$ e $|x|_1 \leq C_2 |x|_\infty$ valem para todo $x \in \mathbb{R}^n$.*

Solução: Temos que

$$\begin{aligned} |x|_\infty &\leq |x_1| + \dots + |x_n| \\ &= |x|_1 \end{aligned}$$

assim podemos tomar $C_1 = 1$. Similarmente,

$$\begin{aligned} |x|_1 &= |x_1| + \dots + |x_n| \\ &\leq n|x|_\infty \end{aligned}$$

logo uma escolha possível é $C_2 = n$.

□

Definição 23. *Seja E um espaço vetorial real. Duas normas $\|\cdot\|_\alpha$ e $\|\cdot\|_\beta$ em E são ditas equivalentes quando existem números reais C_1 e C_2 tais que ambas as desigualdades $\|x\|_\alpha \leq C_1\|x\|_\beta$ e $\|x\|_\beta \leq C_2\|x\|_\alpha$ valem para todo $x \in E$.*

Observação 14. *Esta definição implica que, sabendo o comprimento de vetores na norma $\|\cdot\|_\alpha$, podemos estimar o comprimento de vetores na norma $\|\cdot\|_\beta$. As normas não são as mesmas mas, por exemplo, se um vetor tem comprimento “muito pequeno” em relação a uma norma podemos argumentar que ele tem comprimento pequeno em relação à outra norma.*

Exercício 6. *Verifique que as normas $|\cdot|_\infty$ e $|\cdot|$ definidas acima são equivalentes. Conclua do exemplo 38 acima que $|\cdot|_1$ e $|\cdot|$ também são equivalentes.*

Teorema 6. *Seja E um espaço vetorial de dimensão finita. Então duas normas quaisquer $\|\cdot\|_\alpha$ e $\|\cdot\|_\beta$ são equivalentes.*

Exemplo 39. *Vamos mostrar um caso particular de uma das implicações do teorema acima. Se $\|\cdot\|$ é uma norma qualquer em $\mathbb{R}^n$ então afirmamos que existe $C \in \mathbb{R}$ tal que a desigualdade*

$$\|x\| \leq C|x|_1$$

vale para todo $x \in \mathbb{R}^n$. De fato, escrevendo $x = x_1e_1 + \dots + x_ne_n$ vemos pela definição 22 que

$$\begin{aligned} \|x\| &\leq \|x_1e_1\| + \dots + \|x_ne_n\| \\ &= |x_1|\|e_1\| + \dots + |x_n|\|e_n\| \\ &\leq \max\{\|e_1\|, \dots, \|e_n\|\}(|x_1| + \dots + |x_n|) \\ &= C|x|_1 \end{aligned}$$

com a escolha $C = \max\{\|e_1\|, \dots, \|e_n\|\}$.

7. DIAGONALIZAÇÃO DE MATRIZES

Definição 24. $A_{n \times n}$ é diagonalizável quando existem uma matriz diagonal $D_{n \times n}$ e uma matriz invertível $X_{n \times n}$ tais que $A = XDX^{-1}$.

Teorema 7. $A_{n \times n}$ é diagonalizável se e somente se A possui n autovetores linearmente independentes.

Demonstração. Primeiro, assuma que $v_1, \dots, v_n$ são autovetores linearmente independentes de A associados a autovalores $\lambda_1, \dots, \lambda_n$. Definindo $X = (v_1 \dots v_n)_{n \times n}$ temos que X é invertível e

$$\begin{aligned} AX &= (Av_1, \dots, Av_n)_{n \times n} \\ &= (\lambda_1 v_1, \dots, \lambda_n v_n)_{n \times n} \\ &= XD \end{aligned}$$

$$D = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & \lambda_n \end{pmatrix}.$$

Em particular A é diagonalizável.

Conversamente, é imediato checar que os passos acima são reversíveis, ou seja, se $A = XDX^{-1}$ com D uma matriz diagonal e X invertível então as colunas de X formam uma base de $\mathbb{R}^n$ formada por autovetores de A . Ademais os autovalores associados sendo as entradas da diagonal de D . $\square$

Exemplo 40. Para tentar diagonalizar $A = \begin{pmatrix} 3 & -1 \\ 0 & 2 \end{pmatrix}$ calculamos seus autovalores.

$\det(A - \lambda I) = (3 - \lambda)(2 - \lambda)$ logo A possui dois autovalores $\lambda_1 = 2$ e $\lambda_2 = 3$. Um cálculo imediato nos diz que estes têm autoespaços associados

$$E_1 = \text{Ger}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}$$

$$E_2 = \text{Ger}\left\{\begin{pmatrix} 1 \\ 0 \end{pmatrix}\right\}.$$

Então se $X = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}$, $X^{-1} = \begin{pmatrix} 0 & 1 \\ 1 & -1 \end{pmatrix}$ e $AX = XD$ com $D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$.

Exercício 7. Determine se $A = \begin{pmatrix} 2 & -3 \\ 2 & -5 \end{pmatrix}$ é diagonalizável. Em caso afirmativo encontre X e D tais que $A = XDX^{-1}$.

Exemplo 41. Determine se $B = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ é diagonalizável.

Solução. B possui apenas um autovalor $\lambda = 0$ com autoespaço associado $E = \text{Ger}\left\{\begin{pmatrix} 1 \\ 0 \end{pmatrix}\right\}$. Portanto, B não possui dois autovetores linearmente independentes e, portanto, não é diagonalizável. $\square$

Observação 15. *É útil comparar o exemplo acima com o caso da matriz identidade, a qual é diagonalizável mas também possui apenas um autovalor.*

No caso de autovalores distintos, temos o seguinte critério para obter autovetores linearmente independentes.

Teorema 8. *Seja $A_{n \times n}$. Se $\lambda_1, \dots, \lambda_k$ são autovalores distintos de A com autovetores associados $v_1, \dots, v_k$ então $v_1, \dots, v_k$ são linearmente independentes.*

Demonstração. Seja r a dimensão do conjunto gerado por $v_1, \dots, v_k$. Queremos mostrar que $r = k$. Suponha, por contradição, que $r < k$. Reordenando os vetores, caso preciso, podemos supor que $v_1, \dots, v_r$ são linearmente independentes e $v_1, \dots, v_r, v_{r+1}$ são linearmente dependentes. Então existem números reais $\alpha_1, \dots, \alpha_{r+1}$, nem todos nulos, tais que

$$(12) \quad \alpha_1 v_1 + \dots + \alpha_{r+1} v_{r+1} = \vec{0}.$$

Observe que necessariamente $\alpha_{r+1} \neq 0$ pois de outro modo $v_1, \dots, v_r$ seriam linearmente dependentes. Segue da equação (12) acima que

$$(13) \quad \lambda_{r+1} \alpha_1 v_1 + \dots + \lambda_{r+1} \alpha_{r+1} v_{r+1} = \vec{0}.$$

Por outro lado, aplicando a matriz A aos dois lados de (12) temos

$$(14) \quad \alpha_1 \lambda_1 v_1 + \dots + \alpha_{r+1} \lambda_{r+1} v_{r+1} = \vec{0}.$$

Subtraindo (13) de (14) vemos que

$$(15) \quad \alpha_1 (\lambda_1 - \lambda_{r+1}) v_1 + \dots + \alpha_r (\lambda_r - \lambda_{r+1}) v_r = \vec{0}.$$

Por hipótese, nenhum dos números $(\lambda_j - \lambda_{r+1})$ é zero. Pela independência linear de $v_1, \dots, v_r$ isto implica que $\alpha_1, \dots, \alpha_r$ são todos nulos, o que é uma contradição pois isto implicaria por (12) que $v_{r+1} = 0$. $\square$

Exemplo 42. *Suponha que uma matriz $A_{2 \times 2}$ tem autovalores $\lambda_1 = 2$ e $\lambda_2 = 10$ com autovetores associados $v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ e $v_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$. Calcule A^{2025} .*

Solução. Nesse caso, construímos $X = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$ e sabemos da teoria acima que $A = XDX^{-1}$ para $D = \begin{pmatrix} 2 & 0 \\ 0 & 10 \end{pmatrix}$. Então $A^2 = XDX^{-1}XDX^{-1} = XD^2X^{-1}$ e procedendo indutivamente vemos que $A^{2025} = XD^{2025}X^{-1}$ onde $D^{2025} = \begin{pmatrix} 2^{2025} & 0 \\ 0 & 10^{2025} \end{pmatrix}$, $X = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$ e $X^{-1} = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{-1}{2} & \frac{1}{2} \end{pmatrix}$.

□

7.1. Normas matriciais.

Definição 25. *Seja $M_n(\mathbb{R})$ o espaço das matrizes $n \times n$ com entradas reais. Uma norma matricial $\|\cdot\|$ em $M_n(\mathbb{R})$ é uma norma (no sentido da definição 22) com a seguinte propriedade adicional:*

$$\|AB\| \leq \|A\|\|B\| \text{ para todas } A, B \in M_n(\mathbb{R}).$$

Definição 26. *Se $A = (a_{ij})_{n \times n}$, $\|A\|_2 = \sqrt{\sum_{ij} a_{ij}^2}$ é a norma de Fröbenius de A . Esta norma também é chamada de norma Hilbert-Schmidt de A .*

Exemplo 43. *Se $A = \begin{pmatrix} 2025 & 0 \\ 0 & \frac{1}{2025} \end{pmatrix}$, temos $\|A\|_2 = \sqrt{2025^2 + \frac{1}{2025^2}}$.*

Se $B = \begin{pmatrix} 3 & 3 \\ 3 & 3 \end{pmatrix}$ então $\|B\|_2 = \sqrt{4 \times 3^2} = 6$. Neste caso, observe que $AB = \begin{pmatrix} 3 \cdot 2025 & 3 \cdot 2025 \\ \frac{3}{2025} & \frac{3}{2025} \end{pmatrix}$ logo

$$\begin{aligned} \|AB\| &= \sqrt{2 \cdot 3^2 \cdot 2025^2 + 2 \cdot 3^2 \frac{1}{2025^2}} \\ &= 3\sqrt{2} \sqrt{2025^2 + \frac{1}{2025^2}} \\ &\leq 6 \sqrt{2025^2 + \frac{1}{2025^2}} \\ &= \|A\|\|B\|. \end{aligned}$$

Proposição 11. *Sejam $A, B \in M_n(\mathbb{R})$. Então:*

- (a) $\|A\|_2 = \sqrt{\text{Tr}(AA^T)}$.
- (b) $\|A\|_2 = \sqrt{|Ae_1|^2 + \dots + |Ae_n|^2}$, onde $|Ae_j|$, $j = 1, 2, \dots, n$, denota a norma Euclidiana do vetor Ae_j .

Demonstração. (a) Escreva $A = (a_{ij})_{n \times n}$.

$$\begin{aligned} \text{Tr}(AA^T) &= \sum_{i=1}^n (AA^T)_{ii} \\ &= \sum_{i=1}^n \sum_{k=1}^n A_{ik} A_{ki}^T \\ &= \sum_{i=1}^n \sum_{k=1}^n a_{ik}^2 \end{aligned}$$

(b) Esta é uma mera reformulação da definição. Basta notar que Ae_j é a j -ésima coluna da matriz A . □

Definição 27. Seja $A \in M_n(\mathbb{R})$. A norma do operador de A é o menor número r tal que a desigualdade $|Av| \leq r|v|$ vale para todo $v \in \mathbb{R}^2$, onde $|\cdot|$ denota a norma Euclidiana.

Exemplo 44. $A = \begin{pmatrix} 2025 & 0 \\ 0 & \frac{1}{2025} \end{pmatrix}$ implica, para $v = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ $Av = \begin{pmatrix} 2025v_1 \\ \frac{v_2}{2025} \end{pmatrix}$ assim,

$$\begin{aligned} |Av| &= \sqrt{2025^2 v_1^2 + \frac{v_2^2}{2025^2}} \\ &\leq 2025 \sqrt{v_1^2 + v_2^2} \\ &= 2025|v|. \end{aligned}$$

Logo, $\|A\|_{op} \leq 2025$. Por outro lado, $v = e_1$ implica $|Ae_1| = 2025|e_1|$ logo $\|A\|_{op} \geq 2025$. Concluimos então que $\|A\|_{op} = 2025$.

Proposição 12. Sejam $A, B \in M_n(\mathbb{R})$. Então:

- (a) $\|AB\|_{op} \leq \|A\|_{op}\|B\|_{op}$
- (b) $\|AB\|_2 \leq \|A\|_{op}\|B\|_2$.
- (c) $\|AB\|_2 \leq \|A\|_2\|B\|_2$.

Demonstração. (a) Para todo $v \in \mathbb{R}^n$ temos que

$$|ABv| \leq \|A\|_{op}|Bv| \leq \|A\|_{op}\|B\|_{op}|v|.$$

Em particular, $\|AB\|_{op} \leq \|A\|_{op}\|B\|_{op}$.

(b) A norma Euclidiana da j -ésima coluna de AB é limitada por $|ABe_j| \leq \|A\|_{op}|Be_j|$ logo

$$\begin{aligned} \|AB\|_2 &= \sqrt{|ABe_1|^2 + \dots + |ABe_n|^2} \\ &\leq \sqrt{\|A\|_{op}^2(|Be_1|^2 + \dots + |Be_n|^2)} \\ &= \|A\|_{op}\sqrt{(|Be_1|^2 + \dots + |Be_n|^2)} \\ &= \|A\|_{op}\|B\|_2. \end{aligned}$$

- (c) Por simplicidade denote por A_i a i -ésima linha de A e por B_k a j -ésima coluna de B . Então $|(AB)_{ij}|^2 = |\langle A_i, B_j \rangle|^2 \leq |A_i|^2 |B_j|^2$ pela desigualdade de Cauchy-Schwarz. Assim,

$$\begin{aligned} \|AB\|_2^2 &= \sum_{i=1}^n \sum_{j=1}^n |(AB)_{ij}|^2 \\ &\leq \sum_{i=1}^n \sum_{j=1}^n |A_i|^2 |B_j|^2 \\ &= \|B\|_2^2 \sum_{i=1}^n |A_i|^2 \\ &= \|A\|_2^2 \|B\|_2^2. \end{aligned}$$

□

Exercício 8. Verifique que se $\lambda \in \mathbb{R}$ é um autovalor de A então $|\lambda| \leq \|A\|_{op}$.

7.2. Aplicações.

Exemplo 45. Encontre uma fórmula para o termo geral da sequência de recorrência dada por

$$a_n = 2a_{n-1} + 3a_{n-2}, \quad n \geq 2,$$

onde $a_0 = 0, a_1 = 8$.

Solução. A recorrência acima pode ser escrita como

$$\begin{pmatrix} a_n \\ a_{n-1} \end{pmatrix} = \begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} a_{n-1} \\ a_{n-2} \end{pmatrix}, \quad n \geq 2$$

Iterando, temos

$$\begin{pmatrix} a_n \\ a_{n-1} \end{pmatrix} = A^{n-1} \begin{pmatrix} a_1 \\ a_0 \end{pmatrix}, \quad n \geq 2$$

onde $A = \begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix}$. Então, encontrar o termo geral equivale a calcular as potências de A .

Para isto, devemos diagonalizar esta matriz.

- Autovalores de A :

$$\det(A - \lambda I) = \lambda^2 - 2\lambda - 3$$

portanto A tem os autovalores $\lambda_1 = -1$ e $\lambda_2 = 3$.

- Autoespaço para λ_1 : $E_{\lambda_1} = N(A + I)$ assim $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in E_{\lambda_1}$ quando

$$\begin{pmatrix} 3 & 3 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Daí:

$$E_{\lambda_1} = \text{Ger}\left\{\begin{pmatrix} -1 \\ 1 \end{pmatrix}\right\}.$$

- Autoespaço para λ_2 : $E_{\lambda_2} = N(A - 3I)$ assim $\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \in E_{\lambda_2}$ quando

$$\begin{pmatrix} -1 & 3 \\ 1 & -3 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Daí:

$$E_{\lambda_2} = \text{Ger}\left\{\begin{pmatrix} 3 \\ 1 \end{pmatrix}\right\}.$$

Em particular, os autovetores $v_1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, v_2 = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$ são linearmente independentes logo A é diagonalizável. Escrevendo $X = \begin{pmatrix} -1 & 3 \\ 1 & 1 \end{pmatrix}$ temos $X^{-1} = \frac{-1}{4} \begin{pmatrix} 1 & -3 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} -1/4 & 3/4 \\ 1/4 & 1/4 \end{pmatrix}$. Assim,

$$A^{n-1} = X \begin{pmatrix} (-1)^{n-1} & 0 \\ 0 & 3^{n-1} \end{pmatrix} X^{-1}.$$

Simplificando,

$$\begin{aligned} A^{n-1} &= X \begin{pmatrix} (-1)^{n-1} & 0 \\ 0 & 3^{n-1} \end{pmatrix} X^{-1} \\ &= \begin{pmatrix} (-1)^n & 3^n \\ (-1)^{n-1} & 3^{n-1} \end{pmatrix} X^{-1} \\ &= \begin{pmatrix} \frac{(-1)^{n+1} + 3^n}{4} & \frac{3(-1)^n + 3^n}{4} \\ \frac{(-1)^n + 3^{n-1}}{4} & \frac{3(-1)^{n-1} + 3^{n-1}}{4} \end{pmatrix} \end{aligned}$$

Finalmente

$$A^{n-1} \begin{pmatrix} 8 \\ 0 \end{pmatrix} = \begin{pmatrix} 2[(-1)^{n+1} + 3^n] \\ 2[(-1)^n + 3^{n-1}] \end{pmatrix}$$

e logo

$$a_n = 2[(-1)^{n+1} + 3^n]$$

é a fórmula desejada. □

Vejamos agora um primeiro passo para a modelagem de situações práticas com uso de matrizes.

Exemplo 46. *Suponha que tenhamos duas bibliotecas, b_1 e b_2 , e que livros alugados podem ser devolvidos em qualquer uma das bibliotecas. Com o tempo, observa-se que livros alugados na biblioteca b_1 têm igual probabilidade de serem devolvidos em cada biblioteca, mas livros alugados em b_2 são devolvidos em b_2 com probabilidade $2/3$ e em b_1 com probabilidade $1/3$. Montando a matriz $A = \begin{pmatrix} 1/2 & 1/3 \\ 1/2 & 2/3 \end{pmatrix}$, onde a_{ij} representa a probabilidade de um livro ser alugado na biblioteca b_j e devolvido em b_i , temos que as potências de A*

descrevem a distribuição de livros a longo prazo. Por exemplo, $A \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/2 \\ 1/2 \end{pmatrix}$ nos dá as distribuições de probabilidade após uma devolução se o livro foi alugado em b_1 . Similarmemente, $A \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1/3 \\ 2/3 \end{pmatrix}$ nos dá as distribuições de probabilidade após uma devolução se o livro foi alugado em b_2 . Iterando, se $A^{100} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} p_1 \\ p_2 \end{pmatrix}$, p_1 e p_2 representam as probabilidades de, após 100 devoluções, um livro estar nas bibliotecas b_1 e b_2 , respectivamente. Daí, vemos a importância de ter um método robusto para cálculo de potências matriciais.

Outra aplicação da diagonalização de matrizes é o cálculo funcional de matrizes diagonalizáveis. Vimos acima que $A = XDX^{-1}$ implica $A^l = XD^lX^{-1}$ para todo l . Por linearidade, se $P(z) = a_0 + a_1z + \dots + a_kz^k$ então

$$P(A) = XP(D)X^{-1}$$

onde

$$P(A) = a_0I + a_1A + \dots + a_kA^k$$

$$P(D) = a_0I + a_1D + \dots + a_kD^k.$$

O ponto aqui é que $P(D)$ pode ser calculado explicitamente: se $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ então

$$P(D) = \text{diag}(p(\lambda_1), \dots, p(\lambda_n)).$$

Mais geralmente, suponha que $f(z)$ tem uma expansão de Taylor $f(z) = \sum_{l=0}^{\infty} \frac{f^{(l)}(0)}{l!} z^l$ que converge para $|z| < r$, onde $f^{(n)}$ denota a n -ésima derivada de f (e convencionamos $f^{(0)} = f$). Assuma que $\|A\|_{\text{op}} < r$. É natural definir

$$f(A) = \sum_{n=0}^{\infty} \frac{f^{(n)}(0)}{n!} A^n.$$

É fato que série matricial acima converge e que

$$\|f(A)\|_{\text{op}} \leq \sum_{n=0}^{\infty} \frac{|f^{(n)}(0)|}{n!} \|A\|_{\text{op}}^n.$$

Caso $f^{(n)}(0) \geq 0$ para todo n a última expressão coincide com $f(\|A\|_{\text{op}})$. Outra opção para definir $f(A)$ é a seguinte: cada autovalor de A satisfaz $|\lambda_k| < r$. Lembrando que $A = XDX^{-1}$ definimos

$$f(A) = Xf(D)X^{-1}$$

com

$$f(D) = \text{diag}(f(\lambda_1), \dots, f(\lambda_n)).$$

No contexto acima, esta definição coincide com a definição por série de potências

Exemplo 47. Calcule e^A para a matriz $A = \begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix}$.

Solução. Vimos acima que se $X = \begin{pmatrix} -1 & 3 \\ 1 & 1 \end{pmatrix}$, $X^{-1} = \begin{pmatrix} -1/4 & 3/4 \\ 1/4 & 1/4 \end{pmatrix}$ e

$$A = X \begin{pmatrix} -1 & 0 \\ 0 & 3 \end{pmatrix} X^{-1}.$$

Daí

$$e^A = X \begin{pmatrix} e^{-1} & 0 \\ 0 & e^3 \end{pmatrix} X^{-1}.$$

□

8. MATRIZES DE MARKOV

Definição 28. $A = (a_{ij})_{n \times n}$ é dita uma matriz de Markov, ou estocástica, quando $a_{ij} \geq 0$ para cada $i, j \in \{1, \dots, n\}$ e, além disso,

$$\sum_{i=1}^n a_{ij} = 1$$

para cada $j \in \{1, \dots, n\}$.

Definição 29. $p = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix}$ é um vetor estocástico quando $p_i \geq 0$ para cada $i \in \{1, \dots, n\}$ e

$$\sum_{i=1}^n p_i = 1.$$

Proposição 13. Seja $A_{n \times n}$ uma matriz estocástica e $p \in \mathbb{R}^n$ um vetor estocástico. Então Ap é um vetor estocástico.

Demonstração. Escreva $p = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix}$ e $A = (a_{ij})_{n \times n}$. Então, Para $i \in \{1, \dots, n\}$,

$$(Ap)_i = \sum_k a_{ik} p_k \geq 0.$$

Além disso,

$$\begin{aligned} \sum_{i=1}^n (Ap)_i &= \sum_{i=1}^n \sum_{k=1}^n a_{ik} p_k \\ &= \sum_{k=1}^n p_k \sum_{i=1}^n a_{ik} \\ &= \sum_{k=1}^n p_k \cdot 1 \\ &= 1. \end{aligned}$$

□

Exemplo 48. Na situação do exemplo 46, A é uma matriz estocástica e $Ae_2 = \begin{pmatrix} 1/3 \\ 2/3 \end{pmatrix}$, $A^2(e_2) = A \begin{pmatrix} 1/3 \\ 2/3 \end{pmatrix} = \begin{pmatrix} 1/6 + 2/9 \\ 1/6 + 4/9 \end{pmatrix}$. Note que $1/6 + 2/9 + 1/6 + 4/9 = 1$.

Proposição 14. Sejam $A = (a_{ij})_{n \times n}$ e $B = (b_{ij})_{n \times n}$ matrizes estocásticas. Então AB também é uma matriz estocástica.

Demonstração. Como acima

$$(AB)_{ij} = \sum_{k=1}^n a_{ik}b_{kj} \geq 0$$

e

$$\begin{aligned} \sum_{i=1}^n (AB)_{ij} &= \sum_{i=1}^n \sum_{k=1}^n a_{ik}b_{kj} \\ &= \sum_{k=1}^n b_{kj} \sum_{i=1}^n a_{ik} \\ &= \sum_{k=1}^n b_{kj} \\ &= 1 \end{aligned}$$

□

Proposição 15. Seja A uma matriz de Markov. Se λ é autovalor de A então $|\lambda| \leq 1$. Ademais, A tem um autovalor $\lambda_{\max} = 1$.

Demonstração. Por definição, o vetor $\begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}$ é autovetor de A^T associado ao autovalor 1.

Como A e A^T têm os mesmos autovalores, segue que $\lambda_{\max} = 1$ é autovalor de A . Suponha agora que algum autovalor λ de A seja tal que $|\lambda| > 1$. Então, $|A^n v| = |\lambda|^n |v| \rightarrow \infty$ quando $n \rightarrow \infty$. Em particular, para n grande o suficiente, A^n tem alguma entrada maior do que um o que contradiz o fato desta matriz ser estocástica. □

Teorema 9. (Perron-Frobenius) Seja $A = (a_{ij})_{n \times n}$ uma matriz tal que $a_{ij} > 0$ para cada $i, j \in \{1, \dots, n\}$. Então, existe um número positivo r tal que

- (i) r é autovalor de A .
- (ii) O autoespaço associado a r tem dimensão 1.

- (iii) Existe um autovetor $v = \begin{pmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{pmatrix}$ associado a r tal que $v_j > 0$ para cada $j \in \{1, \dots, n\}$.
- (iv) Qualquer outro autovalor de A satisfaz $|\lambda| < r$.

Exemplo 49. Se A é a matriz do exemplo 46, então A tem autovalores $1/6$ e 1 como pode-se verificar com o matlab. Ademais, o autoespaço associado a $\lambda = 1$ é $E_1 = \text{Ger}\left\{\begin{pmatrix} 2/3 \\ 1 \end{pmatrix}\right\}$ e assim $w = \begin{pmatrix} 2/5 \\ 3/5 \end{pmatrix}$ é o único autovetor estocástico associado ao autovalor $\lambda = 1$.

Observação 16. Sejam A e w com acima. Então, se p é um vetor estocástico qualquer

$$\lim_{n \rightarrow \infty} A^n p = w.$$

De fato, $Ap = c_1 v + c_2 w$, onde v é um autovetor associado ao autovalor $1/6$. Então

$$\begin{aligned} A^n p &= c_1 A^n v + c_2 A^n w \\ &= c_1 (1/6)^n v + c_2 w \\ &\rightarrow c_2 w, \quad n \rightarrow \infty. \end{aligned}$$

Lembrando que $A^n p$ é estocástico para todo p vemos que $c_2 = 1$.
Tal vetor w é dito o estado estacionário de A .